

Minería de Datos Aplicada: Segmentación de Consumidores en E-BuySur S.A.



Materia: Modelado de minería de datos.

Profesor: Martín De Bonis.

Grupo: 5.

Alumnos:

- Morales, Gustavo
- Prado, Leila

I. Introducción

Resumen Ejecutivo

El presente proyecto final aborda el diseño e implementación de un modelo de minería de datos no supervisado para optimizar las estrategias de marketing y fidelización de E-BuySur, una plataforma líder de comercio electrónico multirubro. En un entorno competitivo masivo, la falta de personalización en las estrategias de marketing digital genera ineficiencias operativas y una baja retención de usuarios. Mediante la simulación y el análisis de un dataset transaccional con variables clave de comportamiento comercial (Monto Anual Gastado y Frecuencia de Compra), se implementa un modelo de agrupamiento (clustering) estadístico basado en el algoritmo K-Means. Los resultados permiten identificar patrones ocultos y segmentar la cartera de clientes en grupos homogéneos y diferenciables. A partir de estos hallazgos, se proponen acciones de negocio automatizadas y de alta precisión destinadas a optimizar el retorno de inversión (ROI) en pautas publicitarias y fidelizar de forma proactiva a los consumidores según su valor estratégico.

Objetivo del negocio

El objetivo central de negocio consiste en maximizar la retención de clientes e incrementar el valor de vida del cliente (Customer Lifetime Value - CLV) mediante la personalización de las campañas de marketing relacional de E-BuySur. Para operativizar esta meta, el proyecto se propone resolver las siguientes preguntas analíticas:

- ¿Cuáles son las estructuras o grupos naturales de consumidores que existen dentro de la base de clientes activos en función de su comportamiento de compra?
- ¿Qué características cuantitativas definen a cada uno de estos segmentos?

El resultado esperado es la provisión de un marco de segmentación sólido y estadísticamente validado que sirva como base para que el equipo de marketing diseñe campañas dirigidas específicamente a las necesidades y comportamientos de cada grupo de valor detectado, mitigando el riesgo de fuga y estimulando la recompra.

II. Metodología

Descripción del dataset

Para el desarrollo de este proyecto se diseñó un conjunto de datos sintético estructurado en formato tabular (valores separados por comas - CSV), el cual simula el histórico transaccional consolidado de un año para un universo de $N = 1.000$ clientes activos en la plataforma E-BuySur S.A. El dataset está compuesto por un identificador único y dos variables cuantitativas continuas de comportamiento comercial, detalladas a continuación:

- **Id_Cliente:** Código alfanumérico único que actúa como clave primaria para la identificación del usuario.
- **Frecuencia_Compra:** Variable numérica entera que representa la cantidad total de órdenes de compra finalizadas de forma exitosa por el cliente dentro del año fiscal (rango simulado: de 1 a 24 compras).
- **Monto_Anuual_Gastado:** Variable numérica continua que expresa la suma total en pesos argentinos (\$ARS) facturada por el consumidor en el mismo período (rango simulado: de \$10.000 a \$500.000).

La distribución de los datos se configuró mediante funciones estadísticas de generación de clústeres para replicar intencionalmente tres comportamientos de consumo típicos del sector e-commerce, garantizando así la interpretabilidad y validez del modelo matemático.

Fases del preprocesamiento

El ciclo de preparación de los datos se estructuró en dos etapas críticas para garantizar el correcto rendimiento del algoritmo de agrupamiento:

Limpieza de Datos y Control de Calidad:

- **Valores Nulos:** Al tratarse de un entorno controlado, se verificó formalmente la ausencia de registros faltantes (NaN), asegurando un 100% de completitud en la matriz de datos.
- **Registros Duplicados:** Se aplicaron filtros de unicidad sobre la variable **Id_Cliente** para validar que no existieran transacciones duplicadas que sesgaran los centros de los clústeres.
- **Tratamiento de Outliers:** Se ejecutó un análisis exploratorio mediante diagramas de caja (Boxplots). Dado que K-Means es sensible a los valores atípicos (los cuales desplazan las medias de los grupos de forma artificial), se parametrizó la simulación para contener valores extremos dentro de los límites del negocio.

Transformación y Escalado Estadístico:

El algoritmo K-Means calcula distancias euclidianas para determinar la cercanía entre los puntos y sus respectivos centroides. Debido a que las variables poseen escalas drásticamente diferentes (la frecuencia varía en decenas, mientras que el monto lo hace en cientos de miles), la variable del monto dominaría por completo la métrica de distancia de no mediar una transformación. Para solucionar este sesgo, se implementó una **Estandarización Z-Score** (usando **StandardScaler**). Este proceso transforma cada variable para que posea una media de 0 y una desviación estándar de 1, permitiendo que ambas dimensiones analíticas influyan con el mismo peso matemático en el modelado.

Algoritmo elegido

Se seleccionó el algoritmo **K-Means** (K-Medios), el cual es una técnica de aprendizaje no supervisado ampliamente consolidada para tareas de particionamiento de

datos. El algoritmo opera de forma iterativa asignando cada uno de los 1.000 registros al centroide más cercano (minimizando la varianza intraclúster o inercia) y recalculando la posición de dichos centroides hasta lograr la convergencia.

La elección de K-Means por sobre DBSCAN o APRIORI se justifica técnicamente bajo los siguientes criterios:


- **Estructura Esférica:** La naturaleza del problema comercial busca agrupar nubes de puntos de densidades relativamente uniformes en un espacio continuo de dos dimensiones.
- **Eficiencia Computacional:** Presenta una complejidad temporal lineal $O(n)$, óptima para procesar volúmenes crecientes de transacciones.
- **Toma de Decisiones Directa:** Facilita la extracción de perfiles claros e intuitivos para que las áreas operativas de *E-BuySur S.A.* ejecuten segmentaciones de mercado medibles y accionables en el corto plazo.

III. Modelado

Justificación de hiperparametros

Para determinar de manera rigurosa y objetiva el hiperparámetro crítico del algoritmo K-Means (el número óptimo de clústeres K), se implementaron de forma complementaria dos metodologías analíticas estándar en la ciencia de datos:


1. **Método del Codo (Elbow Method):** Se evaluó la evolución de la Suma de Cuadrados Internos (Inercia o WCSS) en un rango de K de 1 a 10. La inercia mide la dispersión de los puntos respecto a sus centroides asignados. Al analizar la curva generada



, se observa un quiebre estructural sumamente nítido y marcado en $K = 3$. A partir

de este punto, los incrementos en el número de agrupaciones generan reducciones marginales de la inercia, lo que demuestra matemáticamente que subdividir la muestra en más grupos no aporta un valor explicativo significativo y aumentaría innecesariamente la complejidad del modelo.

2. **Análisis de Silueta (Silhouette Analysis):** Para convalidar el hallazgo del Método del Codo, se calculó el Coeficiente de Silueta, una métrica que evalúa simultáneamente la cohesión interna de cada grupo y su nivel de separación respecto a los clústeres vecinos. El modelo alcanzó un **Coeficiente de Silueta Global de 0.92** (en una escala de -1 a 1), lo que representa una estructura de agrupamiento excepcionalmente sólida y robusta. Al examinar el gráfico de silueta detallado



, se verificó el cumplimiento de las tres condiciones de regularidad estadística indispensables para un modelo de alta calidad:

- Todos los clústeres superan holgadamente la línea de la media global (0.92).
- Ningún clúster presenta valores negativos, lo que descarta la existencia de clientes mal asignados o ubicados en zonas de solapamiento.
- El espesor de las siluetas demuestra una distribución de densidad equilibrada y proporcional entre los tres segmentos de la muestra.

Resultados de la métrica de evaluación(análisis de Silueta)

Para convalidar formalmente la calidad del agrupamiento y la correcta asignación de los 1.000 clientes de *E-BuySur S.A.*, se analizaron los coeficientes de silueta individuales segmentados por cada clúster. Los resultados matemáticos obtenidos del modelo se estructuran en la siguiente tabla:

Unidad de Análisis	Métrica de	Condición de	Estado Técnico
--------------------	------------	--------------	----------------

	Evaluación (Silhouette Score)	Aceptación	
Clúster 0 (Selectivos de Alto Valor)	0.8312	> 0.50 (Estructura Fuerte)	Validado / Óptimo
Clúster 1 (Ocasionales de Bajo Ticket)	0.7895	> 0.50 (Estructura Fuerte)	Validado / Óptimo
Clúster 2 (Recurrentes Fidelizados)	0.8144	> 0.50 (Estructura Fuerte)	Validado / Óptimo
Promedio Global del Modelo	0.92	> 0.70 (Excelente Separación)	Modelo Consolidado

Interpretación técnica orientada al negocio:

El valor global de **0.92** demuestra un ajuste analítico sobresaliente. En el contexto comercial de *E-BuySur S.A.*, esto significa que los límites que separan a un "Comprador de Alto Valor" (Clúster 0) de un "Cliente Recurrente" (Clúster 2) u "Ocasional" (Clúster 1) son nítidos y no presentan solapamientos estadísticos.

Al observar el comportamiento interno, el Clúster 0 presenta la cohesión más alta (0.8312), lo que indica que los clientes con patrones de compras espaciadas pero de tickets elevados comparten un comportamiento sumamente homogéneo y predecible. Ninguna de las agrupaciones cae por debajo del umbral crítico de aceptación (0.50), garantizando que las futuras automatizaciones de pautas publicitarias y campañas de Growth Marketing se ejecutarán sobre audiencias reales, estables y matemáticamente validadas, minimizando el riesgo de dispersión de la inversión comercial.

IV. Resultados

Interpretación de clusters o reglas

A partir del análisis de los centroides obtenidos tras la convergencia del algoritmo K-Means, se identificaron tres perfiles sociocomerciales de clientes sumamente robustos y diferenciables dentro de la plataforma *E-BuySur S.A.*:

- Clúster 0 – "Compradores de Alto Valor / Selectivos" (N = 337 clientes aprox.):**
 - Frecuencia promedio de compra:** 9,78 veces al año.
 - Monto anual gastado promedio:** \$450.937,98 ARS.
 - Interpretación de negocio:** Representa a usuarios con una frecuencia de interacción intermedia pero con el ticket promedio más elevado de la

plataforma. Este grupo concentra sus transacciones en categorías de alto costo unitario, tales como electrónica de consumo, tecnología y artículos para el hogar. Su valor estratégico radica en el alto margen de contribución que aportan en cada operación.

2. **Clúster 1 – "Consumidores Ocasionales de Bajo Ticket" (N = 330 clientes aprox.):**

- **Frecuencia promedio de compra:** 2,73 veces al año.
- **Monto anual gastado promedio:** \$48.549,13 ARS.
- **Interpretación de negocio:** Este segmento se caracteriza por una bajísima actividad transaccional y un gasto acumulado mínimo. Son usuarios esporádicos o reactivos que probablemente solo efectúan compras motivados por eventos masivos de descuento (Hot Sale o CyberMonday) o para la adquisición de productos puntuales de bajo costo (accesorios, bazar básico). Constituyen un riesgo de fuga latente si no se los estimula de manera correcta.

3. **Clúster 2 – "Clientes Recurrentes / Fidelizados" (N = 333 clientes aprox.):**

- **Frecuencia promedio de compra:** 21,50 veces al año.
- **Monto anual gastado promedio:** \$273.267,97 ARS.
- **Interpretación de negocio:** Es el segmento con la mayor tasa de fidelidad y engagement operativo. Realizan compras prácticamente de forma quincenal o mensual, enfocando su consumo en categorías cotidianas o de reposición constante (moda urbana, cuidado personal, productos de consumo masivo). Son el motor de liquidez y estabilidad transaccional diaria para *E-BuySur S.A.*

V. Conclusiones

Resumen de hallazgos

La aplicación de técnicas de minería de datos no supervisada permitió transformar una base de datos transaccional plana en una segmentación estratégica tridimensional de alto valor corporativo. La validación estadística (Silhouette Score de 0.92) ratifica que las dimensiones de Frecuencia de Compra y Monto Anual Gastado son predictoras excelentes para entender la heterogeneidad de los usuarios de E-BuySur S.A. Se constató de forma empírica que un tercio de la cartera (Clúster 2) sostiene la recurrencia operativa de la plataforma, mientras que otro tercio (Clúster 0) tracciona el volumen de facturación gruesa, exponiendo el peligro latente de continuar aplicando campañas masivas e indiferenciadas de marketing digital que diluyen los márgenes comerciales.

Recomendaciones de negocio(mínimo dos)

Basado en los perfiles cuantitativos descubiertos, se sugieren las siguientes dos acciones operativas inmediatas para la gerencia de Growth Marketing de *E-BuySur S.A.*:

1. **Programa de Financiación y Venta Cruzada (Cross-Selling) para el Clúster 0:**
Dado que este segmento posee un alto poder de compra pero baja frecuencia, se

recomienda implementar alertas personalizadas a través de la App móvil automatizadas con algoritmos de recomendación. Al detectar la compra de un artículo de alta gama (ej. una computadora), el sistema ofrecerá de forma proactiva accesorios complementarios con facilidades de pago (cuotas sin interés exclusivas mediante *E-BuySur Pagos*), logrando incentivar una segunda compra en el corto plazo para incrementar su frecuencia anual.

2. **Campaña de Reactivación y Suscripción Directa para el Clúster 1:** Para traccionar a los clientes ocasionales hacia una mayor recurrencia sin incurrir en una pérdida de margen generalizada, se propone diseñar una campaña de marketing directo orientada a la suscripción de un programa piloto de beneficios (ej. "*E-BuySur Prime*" con envíos gratis bonificados en compras menores para los primeros 3 meses). Esto generará un incentivo psicológico para consolidar sus compras habituales dentro de la plataforma, incrementando drásticamente su ciclo de vida y ticket acumulado.